

Análisis y optimización matemática de modelos con Naive Bayes en sistemas de almacenamiento para el proyecto Conductome.

Índice

Capítulo 1. Introducción	2
1 Contexto del proyecto Conductoma y Project42.	2
1.2 Estructura de la tesis.	3
1.3 Problema matemático y computacional.	3
1.4 Objetivos.	3
Capítulo 2. Preliminares Matemáticos.	4
2.1 Minería de datos.	4
2.2 Conceptos básicos.	5
2.3 Teorema de Bayes.	7
Capítulo 3. Modelado matemático de Project42.	9
3.1 Naive Bayes.	9
3.2 Construcción de un Score.	10
3.2 Construcción de epsilon.	11
3.3 Formalización de los conjuntos de datos.	12
Capítulo 4. Estrategias de optimización	14
4.1 Complejidad algorítmica.	15
4.3 Elasticsearch vs. GraphQL vs. Clickhouse.	20
4.2 Análisis teórico de cada enfoque para la recuperación de datos.	22
4.3 Elasticsearch vs GraphQL vs Clickhouse.	22
4.4 Análisis de complejidad temporal y espacial.	22
Capítulo 5. Resultados experimentales	22
5.1 Comparación de tiempos de construcción.	22
5.2 Análisis de estabilidad estadística.	22
5.3 Validación empírica de lo teórico.	22
Capítulo 6. Conclusiones	22
6.1 Resultados principales.	22
6.2 Limitaciones.	22
6.3 Trabajo futuro.	22

Capítulo 1. Introducción

1 Contexto del proyecto Conductoma y Project42.

La idea principal del proyecto Conductome y de Project42 es, considerando que todo lo que nos rodea está ahí por una cadena de decisiones elegidas por todos los habitantes de este planeta, busca enfocarse en los problemas que enfrenta la humanidad actualmente como obesidad, hipertensión y diferentes enfermedades crónicas. Mediante un proceso de inferencia estadística, se busca entender mejor cuales son los motivos por los que estos problemas ocurren, desde el punto de vista de la conducta humana.

Una de las claves para la construcción del conductome es contemplar datos que trascienden las disciplinas, mismas que a primera vista pudieran no tener mucha relación, al considerarse como conjunto puedan revelar patrones de comportamiento que deriven en alguno de los problemas mencionados anteriormente.

Sabemos que algunos factores de riesgo importantes para la obesidad van desde lo genético hasta lo económico y político. Conductome busca aportar factores considerando la conducta humana, comportamientos poco saludables durante largos periodos. Comportamientos que a su vez están afectados por nuestro entorno, ambiente obesogénico en el que vivimos y por la percepción del mundo y de nosotros mismos.

Desde el punto de vista matemático, se puede abordar el problema usando inferencia estadística sobre los datos disponibles. Consideramos un conjunto de variables que describen la conducta y características individuales de una población y fijamos una cierta clase objetivo usualmente asociada a un padecimiento de salud como diabetes o hipertensión.

Project42 busca saber si una selección de variables explica “bien” o “mal” a la clase dada, mediante el uso de métricas como el Epsilon y Score, calculados a partir de probabilidades condicionales asociadas a cada categoría se puede concluir sin interpretación que tan bien se explica la clase (o la no clase).

Los detalles formales del modelo, así como de los métodos de estimación y métricas usadas para evaluar la capacidad explicativa de las variables, se desarrollarán con más detalle en capítulos posteriores.

La parte de la implementación computacional puede llegar a ser compleja en estos modelos como se verá más adelante. Sin embargo parte del objetivo de este trabajo es analizar y optimizar desde la recolección de datos hasta el procesamiento de éstos, con el fin de lograr calcular las métricas Epsilon y Score en un tiempo mucho menor al que actualmente se puede conseguir.

1.2 Estructura de la tesis.

El trabajo aquí presentado se organiza de la siguiente manera. En el capítulo 1 se trata de introducir al lector al proyecto Conductome así como a Project42, su contexto e idea general.

En el capítulo 2 se ven los conceptos matemáticos necesarios para el completo entendimiento de los proyectos, incluyendo teorema de Bayes, discretización de variables y la definición de métricas explicativas usadas en Project42 como el epsilon y score de una categoría, entre otros.

En el capítulo 3 se formaliza el modelo en particular usado en Project42, se formalizan las poblaciones utilizadas, las variables objetivo, variables dependientes e independientes.

En el capítulo 4 se analiza la actual implementación de este modelo en la plataforma en línea y se proponen diferentes soluciones tanto en la recuperación de los datos, así como el manejo y flujo de datos para la construcción de las métricas epsilon y score.

En el capítulo 5 vemos los resultados obtenidos de la implementación de las soluciones propuestas. Evaluando y analizando resultados en el performance reales para poder concluir cuál es la solución más eficiente estadísticamente.

En el capítulo 6 el trabajo concluye con una discusión de los resultados, posibles mejoras y limitaciones de la versión actual y propuestas a futuro.

1.3 Problema matemático y computacional.

Detallar problema matemático, calculos de probabilidades, etc.

Podremos notar que generar las métricas Epsilon y Score, usadas para evaluar que tan bien explican las diferentes variables y sus categorías una clase dada, requiere del cálculo repetido de probabilidades condicionales.

La antigua implementación de Project42 hacía este proceso computacionalmente costoso, lo cual limitaba la exploración eficiente de diferentes variables para explicar alguna clase dada, pues los tiempos a esperar para obtener las métricas podía rebasar el minuto de espera, dependiendo de la cantidad de variables a consultar.

1.4 Objetivos.

Tenemos como objetivos principales, explicar la teoría detrás de los proyectos Conductome y Project42, entender el porqué las métricas Epsilon y Score funcionan. Posteriormente pasar a analizar y optimizar el proceso de obtención de estas métricas, mediante la reformulación del flujo de datos, representación de éstos y su procesamiento con el fin de reducir el costo computacional sin alterar ninguna de las propiedades del modelo original.

Objetivos específicos:

- 1.- Formular matemáticamente el modelo estadístico usado en Project42.
- 2.- Analizar la complejidad temporal y espacial del algoritmo que calcula epsilon y score dados un conjunto de variables y una clase.
- 3.- Proponer una implementación en pseudocódigo del algoritmo encargado de calcular las métricas Epsilon y Score.
- 4.- Comparar teórica y empíricamente el desempeño de los diferentes algoritmos propuestos, así como de diferentes filosofías de diseño para la recuperación de los datos usados para el cálculo de Epsilon y Score.

Capítulo 2. Preliminares Matemáticos.

En este capítulo se presentan los fundamentos matemáticos necesarios para el desarrollo del trabajo. Se asume que el lector cuenta con conocimientos básicos de probabilidad, estadística y análisis de algoritmos, ya que se profundizará únicamente los conceptos directamente relacionados con los proyectos Conductome y Project42.

Empezando con conceptos como minería de datos, con el fin de contextualizar el uso de modelos estadísticos en conjuntos de datos con muchas variables (multidimensionales). Después se ven conceptos básicos de probabilidad y estadística que fundamentan los modelos de clasificación usando las métricas Epsilon y Score.

Se introduce el teorema de Bayes así como del clasificador basado en éste Naive Bayes, el cual es fundamental para la construcción del sistema usado en Project42. Se analizan sus variantes para casos continuos y limitantes en términos de clasificación.

Se definen formalmente las métricas Epsilon y Score anteriormente mencionadas y se analiza su desempeño al usarse para la creación de un clasificador binario.

Finalmente se desarrollan algunos criterios para la evaluación de modelos, es decir, buscamos formas para concluir si un modelo es “bueno” para clasificar independientemente de sus datos. Así como nociones de complejidad algorítmica, útiles para determinar el costo computacional de los algoritmos posteriormente propuestos.

2.1 Minería de datos.

Podemos definir a la minería de datos como una rama del análisis de datos que se encarga de encontrar patrones “ocultos”. Con ayuda del poder de cómputo actual la minería de datos es capaz de transformar un conjunto de datos en conocimiento práctico, el cual puede ser utilizado para determinar conductas de consumo, o consecuencias por una toma de

decisiones empresariales, lo cual es de extrema utilidad para las empresas privadas y que puedan aumentar sus márgenes de beneficio.

Una gran diferencia entre la minería de datos y otros métodos de análisis más clásicos, son la cantidad de variables y observaciones utilizadas para obtener conclusiones. Mientras que un acercamiento por análisis más clásico requiere de unos supuestos bien definidos y un número reducido de variables, en la minería de datos usualmente se trabaja con bases de datos con una gran cantidad de variables (cientos o incluso miles) donde no siempre se pueden garantizar supuestos como la independencia.

En el caso de Project42 y Conductome, se usa la minería de datos para entender mejor el alto porcentaje de personas con enfermedades cardiovasculares como obesidad e hipertensión.

2.2 Conceptos básicos.

Axiomas de probabilidad.

Recordemos que un axioma es una proposición que se toma como verdadera y sobre el cual se fundamentan diferentes resultados. Decimos que $\mathbb{P}$ es una función de probabilidad si cumple con los siguientes axiomas.

Sea A un subconjunto de Ω .

1. $\mathbb{P}(A) \geq 0$
2. $\mathbb{P}(\Omega) = 1$
3. La probabilidad de la union numerable de subconjuntos ajenos dos a dos es igual a la suma de las probabilidades individuales. A esta propiedad se le llama aditividad.

Sigma-álgebra.

La idea de una sigma-álgebra es un conjunto que agrupa a todos los eventos de un mismo experimento aleatorio. Aunque a primera vista estos conjuntos parecen bastante abstractos, son extremadamente útiles para los posteriores cálculos de probabilidades.

Decimos que F es una sigma-álgebra de subconjuntos de un conjunto Ω si cumple las siguientes condiciones:

1. $\Omega \in F$
2. Si $A \in F$ entonces $\Omega \setminus A \in F$ (el complemento pertenece a F)
3. Si $A_1, A_2, \dots \in F$ entonces la unión numerable pertenece a F

A los elementos de F se les llama eventos.

Un par de sigma-álgebras inmediatas son $\{\emptyset, \Omega\}$ y $\mathbb{P}(\Omega)$, el conjunto potencia de Ω .

Con este par de conceptos podemos dar paso a la definición de un espacio de probabilidad para un experimento aleatorio.

Un espacio de probabilidad es una terna $(\Omega, F, \mathbb{P})$ donde Ω es un conjunto, F es una sigma-álgebra de subconjuntos de Ω y $\mathbb{P}$ es una función de probabilidad definida sobre F .

Sigma álgebra de Borel.

Probabilidad condicional.

La probabilidad condicional es un concepto sencillo pero que es muy útil para el cálculo de probabilidades, pues ayuda a reducir ciertas probabilidades a expresiones más sencillas.

Sean A y B dos eventos tal que $\mathbb{P}(B) > 0$.

Definimos la probabilidad condicional del evento A dado B , $\mathbb{P}(A | B)$, como:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

La idea intuitiva de la probabilidad condicional es considerar un evento B que ya ha ocurrido y ver cómo esta información adicional influye sobre la probabilidad de A .

Uno puede considerar que usar la probabilidad condicional $\mathbb{P}(A | B)$ es como reducir el espacio muestral Ω al evento B , de tal forma que cualquier evento que ocurra fuera de B tiene probabilidad condicional cero.

Variable aleatoria discreta.

Sea $(\Omega, F, \mathbb{P})$ un espacio de probabilidad. Definimos una variable aleatoria X como una transformación del espacio de resultados Ω al conjunto de números reales, esto es,

$X : \Omega \rightarrow \mathbb{R}$ tal que para cualquier elemento de la sigma álgebra de Borel B , la imagen inversa $X^{-1}(B) \in F$.

(Notación: $(X \in A) = \{w \in \Omega \mid X(w) \in A\}$, que en otras palabras es la imagen inversa de A bajo X . De igual manera con $(X \in (a, b)) = \{w \in \Omega \mid a < X(w) < b\}$.)

Detrás de esta definición que puede parecer muy abstracta, podemos considerar a las variables aleatorias como una pregunta o medición a los resultados de un experimento aleatorio y cuya respuesta es un número real. Para ilustrar la idea veamos un par de ejemplos.

Una observación importante es que cuando Ω es a lo mas numerable y $F = \mathbb{P}(\Omega)$, entonces cualquier función $X : \Omega \rightarrow \mathbb{R}$ cumple con la definición de ser variable aleatoria.

Ejemplo 1.

Consideremos el experimento aleatorio de un volado, esto es, lanzar una moneda equilibrada al aire y ver cuál es la cara que está mirando hacia arriba.

Denotemos por “Cara” y “Cruz” a los dos diferentes lados de la moneda, con esto construimos el espacio muestral $\Omega = \{\text{Cara}, \text{Cruz}\}$ y la sigma álgebra $F = \mathbb{P}(\Omega)$, definimos a la función X de la siguiente manera:

$$X : F \rightarrow \mathbb{R}; X(\text{Cruz}) = 1 \text{ y } X(\text{Cara}) = 0.$$

Por la observación de arriba se sigue que X cumple con ser variable aleatoria. Con esto podemos empezar a calcular algunas probabilidades.

$$\mathbb{P}(X = 1) = \mathbb{P}(\{w \in \Omega \mid X(w) = 1\}) = \mathbb{P}(\{\text{Cruz}\}) = \frac{1}{2}$$

$$\mathbb{P}(X \in [1, 2)) = \mathbb{P}(\{w \in \Omega \mid 1 \leq X(w) < 2\}) = \mathbb{P}(\{\text{Cruz}\}) = \frac{1}{2}$$

$$\mathbb{P}(X \in (10, 20)) = \mathbb{P}(\{w \in \Omega \mid 10 < X(w) < 20\}) = \mathbb{P}(\emptyset) = 0$$

$$\mathbb{P}(X < -1) = \mathbb{P}(\{w \in \Omega \mid X(w) < -1\}) = \mathbb{P}(\emptyset) = 0$$

$$\mathbb{P}(X > 0) = \mathbb{P}(\{w \in \Omega \mid 0 < X(w)\}) = \mathbb{P}(\{\text{Cruz}, \text{Cara}\}) = 1$$

Ejemplo 2.

Consideremos el experimento aleatorio de lanzar dos dados equilibrados. Aquí nuestro espacio muestral queda definido por pares ordenados (a, b) de la siguiente manera:

$$\Omega = \{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\} = \{(a, b) \mid a, b \in \{1, 2, 3, 4, 5, 6\}\}$$

La sigma-álgebra de Ω es $\mathcal{F} = \mathbb{P}(\Omega)$, la potencia de Ω .

Y la función de probabilidad considera dos dados justos y la definimos como $\mathbb{P}(\{(a, b)\}) = \frac{1}{36}$ para todo (a, b) en Ω .

Definamos la variable aleatoria que se fije en la suma de los dados. Sea $S : \Omega \rightarrow \mathbb{R}$; $S((a, b)) = a + b$.

Con esto, podemos calcular algunas probabilidades:

$$\mathbb{P}(S = 7) = \mathbb{P}(\{(a, b) \in \Omega \mid a+b = 7\}) = \mathbb{P}(\{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}) = \frac{6}{36}, \text{ este último paso por aditividad de } \mathbb{P}. \text{ Por lo tanto } \mathbb{P}(S = 7) = \frac{1}{6}.$$

A pesar del nombre, una variable aleatoria no es variable ni aleatoria, pero el nombre se justifica al considerar que los diferentes resultados de un experimento aleatorio son los diferentes números reales x que la función X puede tomar.

Espacio de probabilidad discreto.

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, donde Ω es un conjunto finito o numerable de resultados. $\mathcal{F}$ es la sigma-álgebra de subconjuntos de Ω y $\mathbb{P}$ es una función de probabilidad sobre $\mathcal{F}$.

En el contexto de este trabajo se considerarán únicamente espacios de probabilidad discretos. **** Investigar por qué es importante que NB funciona mejor con espacios discretos.**

2.? Teorema de Bayes.

El teorema de Bayes es uno de esos resultados fundamentales en la teoría de la probabilidad, ya que, permite calcular probabilidades condicionales en términos de la probabilidad condicional invertida, es decir, se pueden calcular probabilidades condicionales a partir de la observación de evidencia.

En el contexto de Project42, se usa el teorema de Bayes para calcular que tan

probable es que una persona pertenezca a una clase de interés dado un conjunto de variables explicativas, probabilidad que eventualmente será útil para la construcción de epsilon y score.

Teorema de Bayes.

Sean A y B dos eventos tales que $\mathbb{P}(B) > 0$. Entonces:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A) \mathbb{P}(A)}{\mathbb{P}(B)}$$

Demostración:

Por definición de probabilidad condicional, tenemos que:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

$$\text{Y que, } \mathbb{P}(B | A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}$$

Despejando $\mathbb{P}(A \cap B)$ de esta última expresión tenemos:

$$\mathbb{P}(A \cap B) = \mathbb{P}(B | A) \mathbb{P}(A)$$

Y sustituyendo en la primera expresión:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A) \mathbb{P}(A)}{\mathbb{P}(B)}$$

En esta expresión, es común encontrar que a los términos se les denomine de la siguiente forma:

$\mathbb{P}(A)$ la probabilidad a priori.

$\mathbb{P}(A | B)$ la probabilidad a posterior.

$\mathbb{P}(B | A)$ se le denomina verosimilitud.

Con este resultado podemos considerar que la probabilidad de una hipótesis se actualiza al agregarse nueva evidencia. En el caso de Project42, la hipótesis corresponde con la pertenencia de un individuo a cierta clase (individuo con diabetes, obesidad, sobrepeso, etc), y la evidencia agregada son los valores observados en las diferentes variables explicativas (edad, actividad física, alimentación, etc).

Odds ratio.

Definición:

Sean X y C dos vectores aleatorios.

Le llamamos la proporción posterior de C_1 respecto a C_2 a la proporción de densidad posterior $\mathbb{P}(C | X)$ evaluada en los puntos C_1 y C_2 .

$$\text{Esto es, } \frac{\mathbb{P}(C_1 | X)}{\mathbb{P}(C_2 | X)}$$

Notemos que al aplicarse el teorema de Bayes a esta expresión se puede reducir a lo siguiente:

$$\frac{\mathbb{P}(C_1|X)}{\mathbb{P}(C_2|X)} = \frac{\mathbb{P}(C_1) \mathbb{P}(X|C_1)/\mathbb{P}(X)}{\mathbb{P}(C_2) \mathbb{P}(X|C_2)/\mathbb{P}(X)} = \frac{\mathbb{P}(C_1) \mathbb{P}(X|C_1)}{\mathbb{P}(C_2) \mathbb{P}(X|C_2)}$$

Usualmente esta expresión es utilizada con parámetros C_1 y C_2 discretos, tales que C_2 es el complemento de C_1 .

Capítulo 3. Modelado matemático de Project42.

En este capítulo buscamos formalizar matemáticamente el sistema implementado en la plataforma de Project42. Más específicamente queremos formalizar los conjuntos de datos, el modelo estadístico utilizado y el criterio usado para evaluar la capacidad explicativa de las variables usadas.

En Project42 se cuenta con cuatro poblaciones, cada una de las cuales cuenta con diferentes características o variables, todas orientadas a encontrar patrones en los padecimientos de salud, sin embargo todas se trataron para compartir una estructura de datos similar, con el objetivo de que la creación de modelos sea independiente del origen de los datos. Con este enfoque, el proyecto puede interpretarse como una plataforma para el análisis explicativo de variables mediante clasificación bayesiana.

Sin embargo, en este capítulo nos enfocaremos en la formalización de los conjuntos de datos utilizados por Project42, así como de la clase objetivo y el conjunto de variables independientes (o explicativas) y a partir de estos elementos calcular y analizar las métricas epsilon y score.

3.1 Naive Bayes.

Naive Bayes es un algoritmo de clasificación que como su nombre lo indica está basado en el teorema de Bayes, en otras palabras, Naive Bayes es una función $NB : \Omega \rightarrow \mathbb{R}$, tal que $NB(X = x)$ nos da la clase más probable a la que pertenece el vector aleatorio $X = x$.

El término Naive (ingenuo) viene de que el algoritmo asume independencia entre las diferentes entradas del vector $X = x$.

Consideremos una muestra aleatoria M , n variables aleatorias $X_1, \dots, X_n$ y una variable objetivo C con k diferentes valores, $C_1, \dots, C_k$. Entonces la idea de Naive Bayes es preguntarse, dada una observación $x_i = (x_{1i}, x_{2i}, \dots, x_{ni})$, cuál es la probabilidad de que x_i pertenezca a la clase C_j para algún $j \leq k$. De esta manera Naive Bayes “predice” que la observación x_i pertenece a la clase que maximiza la siguiente probabilidad:

$$\mathbb{P}(C = C_j | x_i) = \frac{\mathbb{P}(C = C_j) \mathbb{P}(x_i | C = C_j)}{\mathbb{P}(x_i)} \text{ (Teo. Bayes)}$$

Sin embargo, calcular las verosimilitudes ($\mathbb{P}(x_i | C = C_j)$) puede ser complejo y en la práctica algo casi imposible. Se puede dar el caso en que un valor en específico $x_i = (X_1 = x_{1i}, X_2 = x_{2i}, \dots, X_n = x_{ni})$ sea un valor que no exista en el conjunto de datos

o bien el número de observaciones en éste no sea suficiente para estimar con un buen nivel de confianza la probabilidad de pertenencia a la clase.

Aquí es donde el supuesto de independencia entre las diferentes entradas de $X = (X_1, X_2, \dots, X_n)$ entra en juego. Al considerar independencia, podemos considerar lo siguiente:

Sean A y B dos eventos condicionalmente independientes dado un evento C , si:

$$\mathbb{P}(A \cap B \mid C) = \mathbb{P}(A \mid C) \mathbb{P}(B \mid C)$$

Entonces, la verosimilitud $\mathbb{P}(x_i \mid C = C_j)$ se puede calcular de la siguiente manera:

$$\begin{aligned} \mathbb{P}(x_i \mid C = C_j) &= \mathbb{P}(X_1 = x_{1i} \cap X_2 = x_{2i} \cap \dots \cap X_n = x_{ni} \mid C = C_j) \\ &= \mathbb{P}(X_1 = x_{1i} \mid C = C_j) * \dots * \mathbb{P}(X_n = x_{ni} \mid C = C_j), \text{ con } i = 1, 2, \dots, n \end{aligned}$$

Por lo tanto, la probabilidad a posterior queda de la siguiente manera:

$$\mathbb{P}(C = C_j \mid x_i) = \frac{\mathbb{P}(C = C_j) * \mathbb{P}(X_1 = x_{1i} \mid C = C_j) * \dots * \mathbb{P}(X_n = x_{ni} \mid C = C_j)}{\mathbb{P}(x_i)}$$

Con esto, Naive Bayes asigna una observación x_i a la clase $C = C_j$ que maximiza $\mathbb{P}(C = C_j \mid x_i)$

3.2 Construcción de un Score.

Uno de los problemas con Naive Bayes es que no es claro que tanto está aportando cada variable "predictora" para la predicción de la clase objetivo. Una forma ingeniosa de tratar este problema es la propuesta usada por Christopher Stephens en el trabajo *When is Naive Bayes approximation not so naive?*, donde se propone usar log odds para medir la contribución del valor de cada variable predictora a la predicción de la clase objetivo.

Sea C una clase de interés y $\bar{C}$ su complemento y $X = (X_1, X_2, \dots, X_n)$ un vector de variables predictoras.

Ahora, observemos que como C y $\bar{C}$ son complementos, entonces $\mathbb{P}(C \mid X = x) + \mathbb{P}(\bar{C} \mid X = x) = 1$.

Entonces, tenemos que $\mathbb{P}(C \mid X = x) > \mathbb{P}(\bar{C} \mid X = x)$ si y solo si $\frac{\mathbb{P}(C \mid X = x)}{\mathbb{P}(\bar{C} \mid X = x)} > 1$, cuando $\mathbb{P}(\bar{C} \mid X = x) > 0$.

Si ahora consideramos el logaritmo natural de esta proporción, tenemos que: $\log \left(\frac{\mathbb{P}(C \mid X = x)}{\mathbb{P}(\bar{C} \mid X = x)} \right) > 0$ si y solo si $\frac{\mathbb{P}(C \mid X = x)}{\mathbb{P}(\bar{C} \mid X = x)} > 1$.

Por transitividad, obtenemos que: $\mathbb{P}(C \mid X = x) > \mathbb{P}(\bar{C} \mid X = x)$ si y solo si $\log \left(\frac{\mathbb{P}(C \mid X = x)}{\mathbb{P}(\bar{C} \mid X = x)} \right) > 0$.

Una vez con esta intuición, definimos $S(X)$, el score de X para la clase C como el logaritmo de la proporción posterior de C respecto a $\bar{C}$, es decir:

$$S(X) = \log \left(\frac{\mathbb{P}(C \mid X = x)}{\mathbb{P}(\bar{C} \mid X = x)} \right)$$

Notemos que por el teorema de Bayes, se tiene que:

$$\begin{aligned} S(X) &= \log \left(\frac{\mathbb{P}(C) \mathbb{P}(X = x \mid C) / \mathbb{P}(X = x)}{\mathbb{P}(\bar{C}) \mathbb{P}(X = x \mid \bar{C}) / \mathbb{P}(X = x)} \right) \\ &= \log \left(\frac{\mathbb{P}(C) \mathbb{P}(X = x \mid C)}{\mathbb{P}(\bar{C}) \mathbb{P}(X = x \mid \bar{C})} \right) \\ &= \log \left(\frac{\mathbb{P}(C)}{\mathbb{P}(\bar{C})} \right) + \log \left(\frac{\mathbb{P}(X = x \mid C)}{\mathbb{P}(X = x \mid \bar{C})} \right) \end{aligned}$$

Ahora, si aplicamos la independencia condicional de Naive Bayes podemos escribir las verosimilitudes $\mathbb{P}(X = x \mid C)$ y $\mathbb{P}(X = x \mid \bar{C})$ como: $\mathbb{P}(X = x \mid C) = \prod_{j=1}^n \mathbb{P}(X_j = x_j \mid C)$
 $\mathbb{P}(X = x \mid \bar{C}) = \prod_{j=1}^n \mathbb{P}(X_j = x_j \mid \bar{C})$

Denotaremos por $S_{NB}(X_i)$ el score de la variable X_i cuando se asuma la independencia condicional de las variables predictoras sobre la clase. Entonces, $S_{NB}(X) = \log \left(\frac{\mathbb{P}(C)}{\mathbb{P}(\bar{C})} \right) + \sum_{j=1}^n \log \left(\frac{\mathbb{P}(X_j = x_j \mid C)}{\mathbb{P}(X_j = x_j \mid \bar{C})} \right)$

Si denotamos $s(X_j = x_j) = \log \left(\frac{\mathbb{P}(X_j = x_j \mid C)}{\mathbb{P}(X_j = x_j \mid \bar{C})} \right)$, entonces $S_{NB}(X) = \log \left(\frac{\mathbb{P}(C)}{\mathbb{P}(\bar{C})} \right) + \sum_{j=1}^n s(X_j)$

De esta forma, se ha construido un clasificador basado en Naive Bayes $S_{NB}(X)$ que predice que una observación x pertenece a la clase C si $S_{NB}(X) > 0$ y a $\bar{C}$ si $S_{NB}(X) < 0$.

La ventaja de este clasificador es la transparencia sobre sus predictores, pues $s(X_j = x_j)$ representa directamente el aporte del valor x_j en la variable X_j para la predicción de la clase C .

3.2 Construcción de epsilon.

Como se ha ido comentando a lo largo de los capítulos anteriores, la idea detrás de epsilon es obtener una métrica que determine cuando el valor de una variable es estadísticamente significativa para la predictibilidad de una clase de interés.

La manera en que obtendremos epsilon será a través de un test de significancia.

Sea X_i una variable aleatoria y C la clase de interés.

Definimos la hipótesis nula $H_0 : X_i \perp C$.

Y definimos la variable aleatoria K_i como el número de observaciones con la clase C de entre las que tienen $X_i = x_i$.

Con esto, podemos notar que $K_i \sim \text{Binomial}(N_{X_i}, p)$, con $p = \mathbb{P}(C \mid X_i = x_i)$ y N_{X_i}

el número de observaciones con $X_i = x_i$.

Entonces bajo H_0 , tenemos que $\mathbb{P}(C \mid X_i = x_i) = \mathbb{P}(C)$.

Por lo tanto, $E(K_i) = N_{X_i} \mathbb{P}(C)$ y $\text{Var}(K_i) = N_{X_i} \mathbb{P}(C) (1 - \mathbb{P}(C))$.

Y la desviación estándar $\sigma = \sqrt{\text{Var}(K_i)}$.

Con esto, definimos epsilon de la siguiente forma:

$$\varepsilon = \frac{K_{i,obs} - E(K_i)}{\sigma}$$

Por notación, consideramos $K_{i,obs} = N_{CX_i}$.

Notemos que, $N_{CX_i} = \frac{N_{X_i} * N_{CX_i}}{N_{X_i}}$, con $N_{X_i} \neq 0$.

$$\begin{aligned} \text{Entonces, } N_{CX_i} &= \frac{N_{X_i} * \frac{N_{CX_i}}{N}}{\frac{N_{X_i}}{N}} = N_{X_i} * \frac{\mathbb{P}(C \cap X_i)}{\mathbb{P}(X_i)} \\ &= N_{X_i} * \mathbb{P}(C \mid X_i) \end{aligned}$$

Sustituyendo en ε :

$$\varepsilon = \frac{N_{X_i} * \mathbb{P}(C \mid X_i) - N_{X_i} * \mathbb{P}(C)}{\sqrt{N_{X_i} * \mathbb{P}(C) * (1 - \mathbb{P}(C))}} = \frac{N_{X_i} * (\mathbb{P}(C \mid X_i) - \mathbb{P}(C))}{\sqrt{N_{X_i} * \mathbb{P}(C) * (1 - \mathbb{P}(C))}}$$

Además, notemos que como $K_i \sim \text{Binomial}(N_{X_i}, p)$, K_i se puede reescribir como suma de Bernoullis, es decir:

$$K_i = \sum_{t=1}^{N_{X_i}} Z_t, \text{ con } Z_t \sim \text{Bernoulli}(p).$$

Así, cuando N_{X_i} tiende a infinito (en la práctica, cuando es mayor a 30) podemos aplicar el **teorema central del límite**, el cual dice que:

$$\frac{K_i - E(K_i)}{\sqrt{\text{Var}(K_i)}} \sim N(0, 1) \text{ cuando } N_{X_i} \text{ tiende a infinito (o cuando es mayor a 30)}$$

Por lo tanto, bajo H_0 tenemos que $\varepsilon \sim \text{Normal}(0, 1)$, cuando $N_{X_i} > 30$.

Con esto, podemos concluir lo siguiente:

Si $|\varepsilon| < 1.96$, no rechazamos la hipótesis nula, es decir, no hay suficiente evidencia de dependencia entre $X_i = x_i$ y C ; en otras palabras, $X_i = x_i$ no predice C .

Si $|\varepsilon| > 1.96$, en este caso podemos rechazar la hipótesis nula con un nivel de confianza del 95%, es decir, hay evidencia de que X_i y C son dependientes y por lo tanto, $X_i = x_i$ predice C .

Más aún, cuando $\varepsilon > 1.96$, decimos que $X_i = x_i$ es un factor de riesgo para la clase C , pues que un individuo tenga $X_i = x_i$ aumenta la probabilidad de C .

Por otro lado, cuando $\varepsilon < -1.96$ decimos que $X_i = x_i$ es un factor protector, pues si un individuo tiene $X_i = x_i$, la probabilidad de C disminuye.

3.3 Formalización de los conjuntos de datos.

La primera población con la que se empezaron a obtener resultados dentro de Project42 fue la de Estudiantes, Académicos y Trabajadores de la UNAM 2014. La definimos de la siguiente manera:

Sea P una población de interés, en este caso $P = \text{Estudiantes, Académicos y}$

trabajadores de la UNAM, sea D nuestra muestra aleatoria de P de tamaño N , en este caso $N = 1076$.

Para cada individuo $d \in D$, se observan m variables:

$X = (X_1, X_2, \dots, X_m)$, que en nuestro caso $m = 600$.

Donde cada X_i es una función que asigna valores, y pueden ser tanto categóricos como numéricos, en el caso de ser numéricos requiere de una discretización previa. Algunos ejemplos de X_i son:

$X_1 = \text{Edad} \in \mathbb{N}$

$X_2 = \text{Sexo} \in \{M, F\}$

$X_3 = \text{IMC} \in \mathbb{R}^+$

$X_3 = \text{Diabetes} \in \{\text{Sí}, \text{No}\}$

La definición de nuestra clase objetivo siempre se considerará binaria, es decir, $C : D \rightarrow \{0, 1\}$, y podemos considerar a C como la función indicadora sobre el conjunto de individuos por el cual tenemos interés, por ejemplo:

$C = 1\{\text{Diabetes} = \text{"Sí"}\}$

$C = 1\{\text{Presión_sistolica} \geq 140\}$

$C = 1\{\text{Diabetes} = \text{"Sí"}\} \cup \{\text{Fumador} = \text{"Sí"}\}$

De esta forma podemos definir a los conjuntos C^+ y C^- que conformarán a la clase y no clase respectivamente.

$C^+ = \{d \in D \mid C(d) = 1\}$

$C^- = \{d \in D \mid C(d) = 0\}$

Con esto, denotamos:

$N_{C^+} = |C^+|$ y $N_{C^-} = |C^-|$

Veamos un ejemplo concreto:

Sea $C = 1\{\text{Diabetes} = \text{Sí}\}$

$X = \{\text{Edad}, \text{IMC}, \text{Fumador}, \text{Actividad_correr}\}$

Al ser variables numéricas tanto edad como IMC, hacemos una discretización de sus valores, así $\text{Edad} \in \{<26, 27 - 30, 31 - 34, 35 - 38, \dots\}$ e $\text{IMC} \in \{< 18.5, 18.5 - 24.9, 25 - 29.9, > 30\}$.

Con esto, obtenemos:

$N_C = 45$

$\mathbb{P}(C) = 0.04$

$N_{C^-} = 1031$

Y obtenemos los siguientes resultados de epsilon y score para las variables predictoras:

Para la variable Edad:

Valor Epsilon Score

< 26 -2.09 -6.08

27-30 -2.17 -6.16

...

Para IMC:

...

Para Fumador:

...

Para Actividad_correr:

...

Con estos resultados concluimos que los valores significativamente predictivos (con $\alpha = 0.05$) para la clase, es decir que epsilon es mayor a 2, son los siguientes:

Edad > 59.5, IMC = "> 30" "Obeso", Edad = "55 - 59"

De la misma forma, los valores significativamente para la no clase son:

Edad = "30-34", Edad = "26 - 30" y Actividad_correr = "Sí"

Capítulo 4. Estrategias de optimización

Ahora que contamos con un modelo matemático, tanto para ver que tan explicativas son diferentes variables, así como un modelo predictivo podemos proceder a la implementación computacional de éste, sin embargo, puede ser un proceso complejo sobre todo cuando se cuenta con un número elevado tanto de variables como de observaciones.

En el caso de Project42, cada población disponible para crear modelos cuenta con mas de 600 variables cada una y más de 1000 observaciones cada una. El cálculo de un solo modelo requiere de obtener muchas probabilidades condicionales y marginales lo cual no hace nada más que empeorar si se busca calcular multiples modelos.

Este capítulo tiene como objetivo proponer un sistema que abarque desde la recuperación de datos, hasta la construcción de epsilon y score, así como analizar su complejidad algorítmica con el objetivo de que el usuario final pueda obtener un modelo en tiempo razonable.

Para esto, necesitamos saber los fundamentos de la complejidad algorítmica, analizar los diferentes enfoques para la recuperación de datos dados por la herramientas Elasticsearch, GraphQL y Clickhouse, y finalmente proponer un algoritmo para la construcción de epsilon y score, así como analizar su complejidad temporal y espacial.

4.1 Complejidad algorítmica.

La complejidad algorítmica es una herramienta que permite analizar el rendimiento de un algoritmo en términos de su tiempo de ejecución y de su uso en memoria. En otras palabras, la complejidad algorítmica nos dice que tan rápido se ejecuta un algoritmo y cuanta memoria utiliza en función del tamaño de sus entradas.

Es importante aclarar que "rápido" y "cuanta memoria" no se refieren a una cantidad específica de tiempo ni de memoria, pues eso depende de muchos factores como el hardware, lenguaje de programación, sistema operativo o incluso la velocidad conexión a internet. Para esto nos vamos a ayudar de las notaciones asintóticas, las cuales nos van a permitir analizar el comportamiento del algoritmo a medida que sus datos de entrada crezcan.

Para las siguientes definiciones, consideremos las funciones: $f, g : \mathbb{N} \rightarrow \mathbb{R}^+$

Big O.

Esta es la notación asintótica mas usada para analizar la complejidad de un algoritmo, pues nos habla del peor caso, es decir, un algoritmo con entrada a puede ejecutarse en diferentes tiempos dependiendo de a . La notación Big O nos dice que tan rápido crece el tiempo de ejecución (o espacio) considerando el peor caso de a . La definición formal de esta notación es la siguiente:

$$f(n) = O(g(n)) \Leftrightarrow \exists c > 0, \exists n_0 > 0, \forall n > n_0, f(n) \leq c \cdot g(n)$$

Esta notación nos indica que el crecimiento de $f(n)$ es acotado por $g(n)$ a partir de cierto punto n_0 y multiplicado por una constante c . En otras palabras, $f(n)$ no crece más rápido que $g(n)$ para valores grandes de n .

Big Omega.

De manera simétrica a Big O, definimos a Big Omega como:

$$f(n) = \Omega(g(n)) \Leftrightarrow \exists c > 0, \exists n_0 > 0, \forall n > n_0, f(n) \geq c \cdot g(n)$$

Esta notación nos indica que el crecimiento de $f(n)$ es al menos tan rápido como $g(n)$ a partir de cierto punto n_0 y multiplicado por una constante c . En otras palabras, $f(n)$ no crece más lento que $g(n)$ para valores grandes de n . A menudo esta notación es utilizada para describir el mejor caso posible de un algoritmo.

Big Theta.

Big Theta nos habla de cuando f queda atrapada entre dos multiples de g , es decir:

$$f(n) = \Theta(g(n)) \Leftrightarrow \exists c_1, c_2 > 0, \exists n_0 > 0, \forall n > n_0, c_1 \cdot g(n) \leq f(n) \leq c_2 \cdot g(n)$$

Big Theta es exactamente la intersección de Big O y Big Omega, de hecho, se puede demostrar que $f(n) = \Theta(g(n)) \Leftrightarrow f(n) = O(g(n))$ y $f(n) = \Omega(g(n))$. Podemos interpretar a Big Theta como que f crece al mismo ritmo que g para valores grandes de n , o en su defecto, que f es igual en promedio a g para valores grandes de n .

Otra observación importante de Big Theta es que no siempre existe una función g tal que $f(n) = \Theta(g(n))$, es decir, no siempre es posible encontrar una función g que acote a f tanto por arriba como por abajo. Un ejemplo de esto es la función $f(n) = n^{\sin n}$, pues esta función oscila entre n^{-1} y n^1 , se puede probar que no hay función g que acote a f tanto por arriba como por abajo.

Small o

Small o es muy parecido a Big O, con una diferencia sutil pues se debe cumplir para cualquier constante $c > 0$, es decir: $f(n) = o(g(n)) \Leftrightarrow \forall c > 0, \exists n_0 > 0, \forall n > n_0, f(n) < c \cdot g(n)$. Esto lo que nos dice es que f crece mucho más lento que g para valores grandes de n . Podemos notar que $f(n) = o(g(n))$ implica que $f(n) = O(g(n))$.

Algunas propiedades útiles de estas notaciones son las siguientes:

Sean $f, g, h : \mathbb{N} \rightarrow \mathbb{R}^+$, entonces:

Complejidad de una función constante. Si $f(n) = c$ para alguna constante $c > 0$, entonces $f(n) = O(1)$.

Transitividad.

Si $f(n) = O(g(n))$ y $g(n) = O(h(n))$, entonces $f(n) = O(h(n))$.

Suma.

Si $f(n) = O(g(n))$ y $h(n) = O(g(n))$, entonces $f(n) + h(n) = O(g(n))$.

Producto por una constante.

Si $f(n) = O(g(n))$ y $c \in \mathbb{R}^+$, entonces $c \cdot f(n) = O(g(n))$.

Producto.

Si $f(n) = O(g(n))$ y $h(n) = O(k(n))$, entonces $f(n) \cdot h(n) = O(g(n) \cdot k(n))$.

Una observación importante es que las notaciones asintóticas nos dan resultados correctos pero dependiendo de su uso pueden ser muy imprecisas o poco útiles, un ejemplo puede ser una función $f(n) = O(n^2)$, también cumple con $f(n) = O(n^3)$, pero decir que $f(n) = O(n^3)$ no nos da información útil sobre el crecimiento de f . De manera similar, que una función $f(n) = \Omega(n)$ también cumple que $f(n) = \Omega(\log n)$ y que $f(n) = \Omega(1)$, pero esto último no nos da información útil sobre el crecimiento de f . En general se trata de

usar la notación asintótica de la manera mas precisa posible.

Veamos algunos algoritmos comunes y analicemos su complejidad temporal y espacial: Sean $T, S : \mathbb{N} \rightarrow \mathbb{R}^+$ las funciones que representan la cantidad de operaciones realizadas por el algoritmo y la cantidad de memoria utilizada por el algoritmo respectivamente, ambas en función del tamaño de la entrada n .

Acceso a elemento de un arreglo.

```
def access_element(arr, index):  
    return arr[index]
```

Notemos que $T(n) = 1$ para toda $n \in \mathbb{N}$, pues el algoritmo siempre realiza una sola operación independientemente del tamaño o forma de la entrada, por lo tanto podemos acotar su complejidad temporal por una constante, es decir, $T(n) = O(1)$.

Mas aun, $T(n) = \Omega(1)$, pues el algoritmo siempre realiza al menos una operación, por lo tanto $T(n) = \Theta(1)$.

En cuanto a la complejidad espacial, el algoritmo no usa espacio adicional al del arreglo de entrada sin importar el tamaño o forma de la entrada. Por lo tanto, $S(n) = O(1)$, $S(n) = \Omega(1)$ y $S(n) = \Theta(1)$.

Búsqueda lineal.

El algoritmo de búsqueda lineal recorre un arreglo de tamaño n de izquierda a derecha, para determinar si contiene un elemento específico.

```
def linear_search(arr, target):  
    for i in range(len(arr)):  
        if arr[i] == target:  
            return True  
    return False
```

Al analizar este algoritmo podemos considerar que el mejor caso ocurre cuando sin importar el tamaño del arreglo el elemento a buscar siempre está en la primera posición del arreglo, así $T(n) = 1$ para toda $n \in \mathbb{N}$, por lo tanto si proponemos $c = 1$ y $n_0 = 1$, entonces $T(n) \leq c \cdot 1$ para toda $n > n_0$, es decir, $T(n) = O(1)$.

De manera similar, el peor caso ocurriría cuando sin importar el tamaño del arreglo, el elemento a buscar no está en el arreglo, así $T(n) = n$ para toda $n \in \mathbb{N}$, por lo tanto $T(n) = O(n)$.

Y al ser $T(n) = O(n)$ y $T(n) = \Omega(1)$, no existe función g tal que $T(n) = \Theta(g(n))$, pues $T(n)$ no queda atrapada entre dos múltiplos de una función g .

Para la complejidad espacial, la búsqueda lineal no usa espacio adicional al del

arreglo de entrada sin importar el tamaño o forma de la entrada, por lo tanto $S(n) = O(1)$, $S(n) = \Omega(1)$ y $S(n) = \Theta(1)$.

Búsqueda binaria. Este algoritmo tiene el mismo objetivo que la búsqueda lineal, pero cuenta con que el arreglo de entrada esté ordenado. La idea es dividir al arreglo en dos partes iguales y comparar el elemento a buscar con el elemento del medio del arreglo, si son iguales el algoritmo devuelve True, si el elemento a buscar es menor que el elemento del medio, entonces se repite el proceso con el subarreglo izquierdo, de lo contrario se repite el proceso con el subarreglo derecho.

```
def binary_search(arr, target):
    left, right = 0, len(arr) - 1
    while left <= right:
        mid = left + (right - left) // 2
        if arr[mid] == target:
            return True
        elif arr[mid] < target:
            left = mid + 1
        else:
            right = mid - 1
    return False
```

De manera similar a la búsqueda lineal, el mejor caso ocurre cuando sin importar el tamaño del arreglo el elemento a buscar se encuentra en la posición del medio del arreglo, entonces $T(n) = 1$ para toda $n \in \mathbb{N}$, por lo tanto $T(n) = \Omega(1)$. Y de igual forma, el peor caso es cuando el elemento a buscar no se encuentra en el arreglo, dado que el algoritmo divide al arreglo en dos partes iguales en cada iteración, el número de iteraciones que toma para que el arreglo quede con un elemento o vacío es $O(\log_2 n)$, por lo tanto $T(n) = O(\log_2 n)$.

Para la complejidad espacial, búsqueda binaria crea dos variables adicionales para almacenar los índices de los extremos del arreglo en cada iteración, así como una variable para almacenar el índice del medio del arreglo, pero notemos que ésta tercera variable se sobrescriba en cada iteración, por lo cual en todo el algoritmo se usan a lo más tres variables adicionales, por lo tanto $S(n) = O(1)$, $S(n) = \Omega(1)$ y $S(n) = \Theta(1)$.

Bubble Sort. El objetivo de este algoritmo es ordenar un arreglo de tamaño n de menor a mayor. La idea es recorrer el arreglo de izquierda a derecha y comparar cada elemento con el siguiente, si el elemento es mayor al siguiente, entonces se realiza un intercambio entre ambos elementos, de lo contrario se deja el arreglo como está, este

proceso se repite hasta que el arreglo quede ordenado.

```
def bubble_sort(arr):
    n = len(arr)
    for i in range(n):
        for j in range(0, n-i-1):
            if arr[j] > arr[j+1]:
                arr[j], arr[j+1] = arr[j+1], arr[j]
```

Para analizar este algoritmo, hagamos el conteo de operaciones que realiza. Sea arr un arreglo de tamaño n , Primero fijemonos en qué ocurre dentro del ciclo `for` interno, el cual realiza una comparación entre dos elementos del arreglo, lo cual toma tiempo constante, una vez realizada la comparación, si se cumple que el elemento es mayor al siguiente, se realiza el respectivo swap de elementos, lo cual también toma tiempo constante, por lo tanto, sin importar el orden del arreglo, lo que ocurre dentro del ciclo `for` interno toma tiempo constante.

Bien, ahora fijemos $i = 0$, entonces el ciclo `for` interno realiza $n - 1$ iteraciones, por lo cual, el número de operaciones realizadas es de $n - 1$, para $i = 1$ se realizan $n - 2$ operaciones, y así sucesivamente, para $i = n - 1$ se realiza una sola operación, por lo tanto el número total de operaciones realizadas por Bubble Sort es de $(n - 1) + (n - 2) + \dots + 1 = \sum_{i=0}^{n-1} (n - i - 1) = \frac{n(n-1)}{2}$

Probemos que $T(n) = \Theta(n^2)$.

Necesitamos encontrar $c_1, c_2 \in \mathbb{R}$ y $n_0 \in \mathbb{N}$ tales que para todo $n \geq n_0$,

$$c_1 n^2 \leq \frac{n(n-1)}{2} \leq c_2 n^2.$$

Primero veamos que:

$$\frac{n(n-1)}{2} = \frac{n^2 - n}{2} \leq \frac{n^2}{2} = \frac{1}{2}n^2, \forall n \geq 1$$

Por otro lado, también se cumple que:

$$\frac{n(n-1)}{2} = \frac{n^2 - n}{2} \geq \frac{n^2 - n^2/2}{2} = \frac{n^2}{4} = \frac{1}{4}n^2, \forall n \geq 2$$

Pues, $n^2 - n \geq n^2 - n^2/2 \Leftrightarrow -n \geq -n^2/2 \Leftrightarrow n \leq n^2/2 \Leftrightarrow n^2/2 - n \geq 0 \Leftrightarrow n(n/2 - 1) \geq 0$, lo cual es cierto para todo $n \geq 2$.

Por lo tanto, si proponemos $c_1 = 1/4$, $c_2 = 1/2$ y $n_0 = 2$, se cumple que $T(n) = \Theta(n^2)$.

En cuanto a la complejidad espacial, Bubble Sort usa espacio adicional constante para almacenar el tamaño del arreglo y las variables de iteración, por lo tanto, $S(n) = O(1)$, $S(n) = \Omega(1)$ y $S(n) = \Theta(1)$.

Cabe aclarar que existen implementaciones de Bubble Sort más eficientes que pueden hacer que su complejidad temporal sea de $T(n) = \Omega(n)$ en su mejor caso, sin embargo su Big O sigue siendo cuadrático.

4.3 Elasticsearch vs. GraphQL vs. Clickhouse.

La recuperación de datos es el primer proceso para la construcción de nuestro sistema, y es uno de los pasos más importantes, pues la eficiencia de éste puede empeorar significativamente el tiempo total de construcción de modelos, dando una mala experiencia al usuario final.

En este apartado analizamos los diferentes enfoques que usan las herramientas Elasticsearch, GraphQL y Clickhouse para la recuperación de datos, para así poder elegir la opción que mejores resultados nos de en términos de complejidad temporal para nuestro caso en particular.

Recordemos que el objetivo del sistema es obtener un modelo predictivo y explicativo para una clase de interés, para esto, haremos el calculo de epsilon y score mediante conteos de observaciones, mas especificamente y usando la notación de la sección 3.3, necesitamos obtener los siguientes conteos: N , N_{C+} , N_{C-} , N_{X_i} , N_{C+X_i} y N_{C-X_i} para cada variable X_i .

Por lo cual, la herramienta que elijamos debe ser capaz de devolvernos los datos necesarios para posteriormente calcular estos conteos.

Elasticsearch.

Elasticsearch es una herramienta principalmente pensada para almacenar, buscar y filtrar información de forma rápida. Una forma sencilla de imaginarlo es como un índice en un libro, en lugar de leer todo el libro para encontrar la información que buscas, primero consultas en el índice y así puedes llegar más rápido al contenido que buscas.

Para conseguir esto, Elasticsearch guarda los datos en una estructura llamada "documento", y crea una estructura interna llamada "índices" que le permite localizar datos sin tener que revisar todos los datos desde cero. Esto lo vuelve especialmente útil para búsquedas donde hay que filtrar mucho los datos y devolver únicamente un pequeño subconjunto de los datos totales.

De manera simplificada, Elasticsearch funciona de la siguiente manera: 1. Se cargan los datos en forma de documentos, cada documento representa una observación con sus respectivas variables. 2. Elasticsearch construye índices para acelerar búsquedas y filtros.

3. El usuario realiza una consulta con ciertos filtros y condiciones. 4. El sistema responde con una estructura de datos conteniendo los registros que cumplen con esas condiciones y con los campos solicitados.

La idea clave es que Elasticsearch es muy eficiente para responder preguntas del tipo: "Dame solo los individuos que cumplen estas condiciones, y solo con estas variables".

GraphQL.

A diferencia de Elasticsearch, GraphQL no es una base de datos ni un sistema de almacenamiento, sino una forma de pedir datos a un servidor. Una forma sencilla de verlo es como un mesero en un restaurante, en lugar de que se le proporcione un menú fijo al cliente, el cliente pide exactamente lo que quiere, y el mesero se encarga de traerlo.

En sistemas más tradicionales, cuando se hacen consultas a servidores, muchas veces se regresa información que no es necesaria, o bien se requieren de múltiples consultas para obtener toda la información requerida. GraphQL busca resolver esto permitiendo que el cliente especifique exactamente qué datos necesita.

De forma simplificada, GraphQL funciona así: 1. Se define un esquema (schema) que describe los tipos de datos disponibles y cómo se relacionan entre sí. 2. El cliente envía una consulta al servidor especificando exactamente los campos que necesita. 3. El servidor procesa la consulta accediendo a la base de datos. 4. El servidor devuelve los datos solicitados y en el formato especificado por el cliente.

Aquí, la idea fundamental para el uso de GraphQL es que el usuario puede pedir exactamente la información que necesita, evitando recibir información innecesaria.

Clickhouse.

Clickhouse es una base de datos diseñada para manejar grandes volúmenes de datos de forma muy rápida. El enfoque para conseguir esto es a través de una arquitectura orientada a columnas, no por filas completas como en las bases de datos tradicionales.

De manera sencilla, Clickhouse funciona de la siguiente manera: 1. Inicialmente se almacenan los datos en en tablas, después internamente se organizan por columnas. 2. Cuando el usuario hace una consulta, Clickhouse accede solo a las columnas necesarias para responder la consulta. 3. Clickhouse utiliza técnicas de compresión y paralelización para acelerar el procesamiento de consultas. 4. El sistema devuelve los resultados de la consulta al usuario.

Un detalle importante que vuelve a Clickhouse muy rápido al hacer consultas, es su forma de paralelizar el procesamiento de consultas, es decir, puede dividir una consulta en partes más pequeñas y hacer uso de múltiples núcleos de procesamiento para responder la

consulta completa más rápido.

Habiendo considerado los tres enfoques, una observación a tener en cuenta es que con una implementación adecuada, los tres enfoques comparten la misma complejidad temporal $O(nm)$, sin embargo, en el siguiente capítulo se muestra que el rendimiento temporal de los tres enfoques varía significativamente, lo cual se explica principalmente por factores constantes y de arquitectura, no por el orden asintótico.

Aún así, a simple vista y considerando nuestro caso particular, el enfoque que parece más adecuado es el de Clickhouse, pues su capacidad de paralelización y sobre todo su arquitectura orientada a columnas lo hacen muy atractivo, ya que la gran mayoría de las consultas que se harán para obtener los modelos no requerirán de todas las variables.